

概率论与数理统计

第七章 参数估计

第七章 参数估计

7.1 参数估计概念

7.2 矩估计法和极大似然估计法

7.3 估计量的评选标准

7.4 区间估计

第七章 参数估计

7.1 参数估计概念

7.1 参数估计概念

——根据样本给出参数的估计值

θ 是 $F(x, \theta)$ 中的未知参数 $\theta \in \Theta$

样本 (X_1, X_2, \dots, X_n)

估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$

估计区间 $\hat{\theta}_1(X_1, \dots, X_n), \hat{\theta}_2(X_1, \dots, X_n)$

估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$

$\theta \in (\hat{\theta}_1, \hat{\theta}_2)$

θ

点估计

区间估计

第七章 参数估计

7.2 矩估计法和极大似然估计法

7.2.1 矩估计法

1 原理: 大数定理, $P\left(\left|\frac{1}{n}\sum_{i=1}^n X_i^k - E(X^k)\right| < \epsilon\right) \rightarrow 1$ 在 $E(X^k)$ 上逼近总体矩。

总体 X 的分布函数 $F(x; \theta_1, \dots, \theta_k)$, 其中 $\theta_1, \dots, \theta_k$ 为待估参数.
(X_1, \dots, X_n)为 X 的样本(设 X 的 k 阶矩存在), 则

总体的 j 阶原点矩 $E(X^j) = a_j(\theta_1, \dots, \theta_k)$

样本的 j 阶原点矩 $\frac{1}{n} \sum_{i=1}^n X_i^j = A_j$

2 方法 令 $a_j(\theta_1, \dots, \theta_k) = A_j \quad j=1, \dots, k$

求解方程组, 得到解 $\hat{\theta}_1, \dots, \hat{\theta}_k$ 作为参数 $\theta_1, \dots, \theta_k$ 的矩估计量.

7.2.1 矩估计法

例 试求总体期望 $\theta_1=EX$ 和方差 $\theta_2=DX$ 的矩估计。

解

$$\begin{aligned} \text{令} \begin{cases} EX = \bar{X} \\ EX^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases} &\Leftrightarrow \begin{cases} \theta_1 = \bar{X} \\ \theta_2 + \theta_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases} \\ \Leftrightarrow \begin{cases} \theta_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \tilde{S}^2 \\ \theta_1 = \bar{X} \end{cases} &\therefore \hat{\theta}_1 = \bar{X}, \quad \hat{\theta}_2 = \tilde{S}^2. \end{aligned}$$

注1 此结论对期望和方差存在的总体都适用，即

$$\hat{E}(X) = \bar{X}, \quad \hat{D}(X) = \tilde{S}^2.$$

注2 估计不唯一，如对总体 $P(\lambda)$ 有 $\hat{\lambda} = \bar{X}$, $\hat{\lambda} = \tilde{S}^2$.

注3 可用 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ 估计 $\beta_k = E(X - EX)^k$.

7.2.1 矩估计法

例 设总体 $X \sim U[a, b]$, 试由样本 (X_1, X_2, \dots, X_n) , 求未知参数 a, b 的矩估计量。

解

$$(1) \quad \begin{cases} \alpha_1 = E(X) = \frac{a+b}{2} \\ \beta_2 = D(X) = \frac{(b-a)^2}{12} \end{cases} \Rightarrow \begin{cases} a = \alpha_1 - \sqrt{3\beta_2} \\ b = \alpha_1 + \sqrt{3\beta_2} \end{cases}$$

$$(2) \quad \begin{cases} \hat{a} = A_1 - \sqrt{3B_2} = \bar{X} - \sqrt{3\tilde{S}^2} \\ \hat{b} = A_1 + \sqrt{3B_2} = \bar{X} + \sqrt{3\tilde{S}^2} \end{cases}$$

[缺点] 如 $\frac{1}{2}, \frac{1}{3}, \frac{1}{4}, \dots, \frac{1}{11}$ 为来自 $X \sim U[a, b]$ 的样本观察值, 则 a, b 的估计值为 $\hat{a} = -0.01$, $\hat{b} = 0.414$. 注意到: $x_1 = 0.5 > \hat{b}$

一般 $P(\hat{a} < \min X_i) > 0$, $P(\hat{b} > \max X_i) > 0$

7.2.2 极大似然估计法

引例 设 $X \sim B(1, p)$, p 未知. 设想我们事先知道 p 只有两种可能:

$$p=0.8 \quad \text{或} \quad p=0.1$$

抽样结果: 1, 1, 0, 1.

问: 应如何估计参数 p ?

解: $P(X_1 = 1, X_2 = 1, X_3 = 0, X_4 = 1) = p^3(1-p).$

参数 p	观测值出现的概率
0.8	0.1024
0.1	0.0009

故参数 p 的极大似然估计值是0.8

7.2.2 极大似然估计法

1. 原理

极大似然原则： 已发生的事件，其概率应该最大。

极大似然估计 (Maximum Likelihood Estimation, MLE)

总体 X 的分布形式**已知**，未知的仅仅是参数 $\theta \in \Theta$

$$x_1, \dots, x_n$$

参数 θ 的选择应有利于样本观测值的发生，即让这组数据发生的概率达到最大。

7.2.2 极大似然估计法

似然函数:

$\theta=(\theta_1,\dots,\theta_k)$ 为待估未知参数,
 (x_1,\cdots,x_n) 为样本 (X_1,\cdots,X_n) 的一组观测值。

$$L(x_1, x_2, \cdots, x_n; \theta) = \begin{cases} \prod_{i=1}^n f(x_i; \theta) & \text{其中 } f(x; \theta) \text{ 为 } X \text{ 的密度函数} \\ \prod_{i=1}^n P_{\theta}(X = x_i) & \text{其中 } P_{\theta}(X = x) \text{ 为 } X \text{ 的分布律} \end{cases}$$

θ 的极大似然估计值 $\hat{\theta}(x_1, x_2, \cdots, x_n)$:

$$L(x_1, x_2, \cdots, x_n; \hat{\theta}) = \max_{\theta} L(x_1, x_2, \cdots, x_n; \theta)$$

θ 的极大似然估计量 $\hat{\theta}(X_1, X_2, \cdots, X_n)$

7.2.2 极大似然估计法

2. 一般步骤

选 $\hat{\theta}$ 使 $L(\theta)$ 最大

(1) 写出似然函数 $L(\theta)$

(2) 建立似然方程(组) $\frac{\partial L(\theta)}{\partial \theta_i} = 0$ 或 $\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0$.

(3) 解方程(组)得极大似然估计 $\hat{\theta}$

7.2.2 极大似然估计法

例 $X \sim P(\lambda)$, 求 λ 的极大似然估计。

解：设 (x_1, \dots, x_n) 为样本的一组观测值，

似然函数
$$L(\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum_{i=1}^n x_i}}{x_1! \cdots x_n!} e^{-n\lambda}$$

$$\ln L = -n\lambda + \sum_{i=1}^n x_i \ln \lambda - \sum_{i=1}^n \ln(x_i!)$$

似然方程
$$\frac{d \ln L}{d \lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^n x_i = 0$$

解方程 λ 的极大似然估计为：
$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

比如，样本观测值为：10, 13, 65, 18, 79, 42, 65, 77, 88, 123, $n=10$ 。则 $\hat{\lambda} = \bar{x} = 58$ 。

7.2.2 极大似然估计法

例 设总体 $X \sim N(\mu, \sigma^2)$ 和样本观测值 x_1, \dots, x_n , 求 μ 和 σ^2 的极大似然估计。

解
$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

$$\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\begin{cases} \frac{\partial}{\partial \mu} \ln L = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = \frac{1}{\sigma^2} (n\bar{x} - n\mu) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases}$$

$$\Rightarrow \hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \tilde{s}^2$$

7.2.2 极大似然估计法

例 设总体 $X \sim U[a, b]$ 和样本观测值 x_1, \dots, x_n , 试求 a 和 b 的极大似然估计。

解

$$L(a, b) = \prod_{i=1}^n f(x_i; a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_1, x_2, \dots, x_n \leq b \\ 0, & \text{others} \end{cases}$$

$$\because a \leq x_1, x_2, \dots, x_n \leq b,$$

$$a \uparrow, b \downarrow \Rightarrow (b-a) \downarrow \Rightarrow L(a, b) \uparrow$$

$$\therefore a = \min_{1 \leq i \leq n} \{x_i\}, b = \max_{1 \leq i \leq n} \{x_i\}, \quad L(a, b) = \max.$$

即 a, b 的极大似然估计为 $\hat{a} = X_1^*, \hat{b} = X_n^*$.

7.2.2 极大似然估计法

3. 性质

若 $\hat{\theta}$ 为 θ 的极大似然估计, $u=u(\theta)$ 有唯一反函数 $\theta = \theta(u)$, 则 $\hat{u} = u(\hat{\theta})$ 为 $u=u(\theta)$ 的极大似然估计。

例 设总体 $X \sim N(\mu, \sigma^2)$, 求 σ 的极大似然估计。

解 $\sigma > 0, \sigma = \sqrt{\sigma^2}$ 有反函数。由上例, $\hat{\sigma}^2 = \tilde{s}^2$

故
$$\hat{\sigma} = \tilde{s} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

第七章 参数估计

7.3 估计量的评选原则

7.3.1 无偏性

1. 定义 设 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 为参数 θ 的估计量, 若

$$E(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的**无偏估计量**.

记 $b_n = E\hat{\theta} - \theta$ —— 估计量 $\hat{\theta}$ 的偏差

若 $b_n \neq 0$ —— $\hat{\theta}$ 是 θ 的**有偏估计**

若 $\lim_{n \rightarrow \infty} b_n = 0$ —— $\hat{\theta}$ 是 θ 的**渐进无偏估计**

例1 证明样本均值 \bar{X} 为总体期望 $\mu = E(X)$ 的无偏估计。

解
$$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = E(X) = \mu$$

一般
$$E(A_K) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = E(X^k) = \alpha_k$$

7.3.1 无偏性

例2 证明样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 $D(X)=\sigma^2$ 的无偏估计。

证明
$$E(S^2) = E\left[\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)\right]$$

$$= \frac{1}{n-1} [nE(X_1^2) - nE(\bar{X}^2)]$$

$$\frac{D(X) = E(X^2) - (EX)^2}{E(X^2) = D(X) + (EX)^2} \rightarrow = \frac{1}{n-1} [n(\sigma^2 + \mu^2) - n(D(\bar{X}) + \mu^2)]$$

$$= \frac{1}{n-1} [n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2]$$

$$= \sigma^2$$

7.3.1 无偏性

注1 例2说明 $\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 不是 σ^2 的无偏估计。

$$\because E(\tilde{S}^2) = E\left(\frac{n-1}{n} S^2\right) = \frac{n-1}{n} \sigma^2 \xrightarrow{n \rightarrow \infty} \sigma^2$$

~ 渐近无偏估计

注2 $\hat{\theta}$ 为 θ 的无偏估计, 但 $u(\hat{\theta})$ 不一定是 $u(\theta)$ 的无偏估计。

例如: 若 $D(X) > 0$, 则

$$E[(\hat{\mu})^2] = E(\bar{X}^2) = D(\bar{X}) + [E(\bar{X})]^2 > [E(\bar{X})]^2 = \mu^2$$

注3 无偏估计不唯一, 如 X_1 和 \bar{X} 均为 $\mu = E(X)$ 的无偏估计。

事实上对任何 c_1, c_2, \dots, c_n , 当 $c_1 + c_2 + \dots + c_n = 1$ 时,

$$E\left(\sum_{i=1}^n c_i X_i\right) = \mu$$

7.3.2 有效性

1. 定义 设 $\hat{\theta}_1$, $\hat{\theta}_2$ 都是参数 θ 的无偏估计量, 若

$$D(\hat{\theta}_1) < D(\hat{\theta}_2)$$

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效.

比如 $E(X_1) = E(\bar{X}) = \mu$, 但 $D(X_1) = \sigma^2$, $D(\bar{X}) = \frac{1}{n} \sigma^2$

故 $\hat{\mu} = \bar{X}$ 比 $\hat{\mu}_1 = X_1$ 有效。

设 $\hat{\theta}_0$ 是参数 θ 的无偏估计量, 若对 θ 的任一无偏估计 $\hat{\theta}$, 有

$$D(\hat{\theta}_0) \leq D(\hat{\theta})$$

则称 $\hat{\theta}_0$ 是 θ 的最小方差无偏估计.

7.3.2 有效性

例3 在总体期望 $\mu = E(X)$ 的线性无偏估计类

$$\bar{U} = \left\{ \hat{\mu} = \sum_{i=1}^n c_i X_i \mid \sum_{i=1}^n c_i = 1 \right\} \text{ 中求 } \mu \text{ 最小方差无偏估计。}$$

解 $E(\hat{\mu}) = \sum_{i=1}^n c_i E(X_i) = \sum_{i=1}^n c_i \mu = \mu, \quad \hat{\mu} \in \bar{U}$

由**Cauchy-Schwarz**不等式 $(\sum_{i=1}^n a_i b_i)^2 \leq (\sum_{i=1}^n a_i^2)(\sum_{i=1}^n b_i^2)$

$$\begin{aligned} D(\hat{\mu}) &= \sum_{i=1}^n c_i^2 D(X) = \frac{1}{n} \left(\sum_{i=1}^n 1^2 \right) \left(\sum_{i=1}^n c_i^2 \right) D(X) \\ &\geq \frac{1}{n} \left(\sum_{i=1}^n 1 \times c_i \right)^2 D(X) = \frac{1}{n} D(X) \end{aligned}$$

而 $D(\bar{X}) = \frac{1}{n} D(X)$, 故 $\hat{\mu}_0 = \bar{X}$ 是 μ 的最小方差线性无偏估计。

7.3.2 一致性

1.定义 设 $\hat{\theta}$ 是参数 θ 的估计量, 若对任意 $\varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| < \varepsilon) = 1 \quad \text{即 } \hat{\theta} \xrightarrow{P} \theta.$$

则称 $\hat{\theta}$ 为 θ 的一致估计量.

例 由大数定律 $\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| < \varepsilon) = 1$

知样本均值 \bar{X} 是总体均值 μ 的一致估计。

7.3.2 一致性

例 证明正态总体的样本方差 S^2 是 σ^2 的一致估计。

证 $\because \frac{n-1}{\sigma^2} S^2 \sim \chi^2(n-1) \quad E(S^2) = \sigma^2,$

$$DS^2 = D\left(\frac{\sigma^2}{n-1} \cdot \frac{(n-1)}{\sigma^2} S^2\right) = \frac{\sigma^4}{(n-1)^2} D\left(\frac{(n-1)}{\sigma^2} S^2\right) = \frac{2\sigma^4}{(n-1)}.$$

由切比雪夫不等式

$$P(|S^2 - \sigma^2| < \varepsilon) \geq 1 - \frac{2\sigma^4}{(n-1)\varepsilon^2} \xrightarrow{n \rightarrow \infty} 1.$$